

The background is a dark gray canvas filled with a complex, abstract composition of various data visualization elements. On the left side, there are three vertically stacked charts: a line graph with multiple overlapping curves, a line graph with two distinct wave patterns, and a bar chart with numerous vertical bars of varying heights. On the right side, there are three vertically stacked charts: a line graph with a jagged, mountain-like curve, a line graph with a series of sharp vertical spikes, and a line graph with a single smooth wave. Scattered throughout the center and right are several circular pie charts with different segment colors (orange, red, yellow, white), numerous small circles of various colors, and thin white lines that connect some of these elements, creating a network-like structure. Large, semi-transparent, wavy shapes in shades of orange, red, and yellow are layered across the center, partially obscuring the other elements. The overall aesthetic is technical and analytical, suggesting a focus on data and causality.

Einführung in die Kausalität

Einführung in die Kausalität

Korrelation ist nicht gleich Kausalität

Einführung in die Kausalität

Korrelation ist nicht gleich Kausalität

Außer, wenn Korrelation gleich Kausalität!

Einführung in die Kausalität

Korrelation ist nicht gleich Kausalität

Außer, wenn Korrelation gleich Kausalität!

Woher wissen wir, dass X zu Y führt?

Einführung in die Kausalität

Korrelation ist nicht gleich Kausalität

Außer, wenn Korrelation gleich Kausalität!

Woher wissen wir, dass X zu Y führt?

X führt zu Y, wenn ...

Einführung in die Kausalität

Korrelation ist nicht gleich Kausalität

Außer, wenn Korrelation gleich Kausalität!

Woher wissen wir, dass X zu Y führt?

X führt zu Y , wenn ...

wir eingreifen und X verändern, alles andere jedoch gleich lassen und ...

Einführung in die Kausalität

Korrelation ist nicht gleich Kausalität

Außer, wenn Korrelation gleich Kausalität!

Woher wissen wir, dass X zu Y führt?

X führt zu Y, wenn ...

wir eingreifen und X verändern, alles andere jedoch gleich lassen und ...

Y sich danach verändert.

Achtung: Y "hört" jedoch nicht unbedingt nur auf X. Es gibt potentiell noch andere Einflüsse, die auf Y einwirken.

Beispiele für kausale Aussagen

- + Feuerwerkskörper verursachen Lärm, sobald diese angezündet werden
- + Das Krähen des Hahn führt zum Sonnenaufgang
- + Ein Bachelor an der Uni Ulm erhöht ihr späteres Einkommen

Beispiele für kausale Aussagen

- + Feuerwerkskörper verursachen Lärm, sobald diese angezündet werden
- + Das Krähen des Hahn führt zum Sonnenaufgang
- + Ein Bachelor an der Uni Ulm erhöht ihr späteres Einkommen

Kausalität = Korrelation + zeitliche Abfolge + kein Scheinzusammenhang

Woher wissen Sie, dass Sie die richtigen Faktoren betrachten (d.h. keinen Scheinzusammenhang)?

Beispiele für kausale Aussagen

- + Feuerwerkskörper verursachen Lärm, sobald diese angezündet werden
- + Das Krähen des Hahn führt zum Sonnenaufgang
- + Ein Bachelor an der Uni Ulm erhöht ihr späteres Einkommen

Kausalität = Korrelation + zeitliche Abfolge + kein Scheinzusammenhang

Woher wissen Sie, dass Sie die richtigen Faktoren betrachten (d.h. keinen Scheinzusammenhang)?

Hier benötigen Sie ein Modell -> Etwas was Sie in dieser Vorlesung lernen!

Datengenerierungsprozess

Um zu verstehen, wie wir aus experimentellen Daten oder aus Beobachtungsdaten *kausale* Zusammenhänge ableiten können müssen wir uns folgenden Fragen widmen:


- + Woher stammen unsere Daten (Experiment oder Beobachtungsdaten)?
- + Welcher **Datengenerierungsprozess** hat diese Daten erzeugt?
- + Können wir auf diesen Datengenerierungsprozess einwirken? (insbesondere durch ein Experiment)
- + Gibt es zufällige Elemente in unseren Daten die wir analysieren könnten?

Kausale Graphen (DAGs)

Um uns den Datengenerierungsprozess vor Augen zu führen sollten wir diesen modellieren:

- + Hierzu verwenden wir die **directed acyclic graphs (DAGs)**, welche vor allem von Judea Pearl entwickelt wurden
- + In diesen DAGs fließt Kausalität (acyclic) nur in eine Richtung (falls Rückwärtskausalität oder Simultanität vorhanden ist sind andere Modelle besser geeignet)
- + DAGs präsentieren Kausalität als Alternativszenario ("counterfactuals")
 - + Ein kausaler Effekt wird als Vergleich zweier Alternativen definiert:
 - + Der Zustand der stattgefunden hat mit der Intervention
 - + Der Zustand der nicht stattgefunden hat ohne die Intervention (das "counterfactual")


Wie groß war der Effekt einer Intervention?



Quelle: Andrew Heiss, Programm evaluation (<https://evalf20.classes.andrewheiss.com/content/01-content/>)

Wie messen wir den Effekt einer Intervention?

Wie groß war der Effekt einer Intervention?




Quelle: Andrew Heiss, Programm evaluation (<https://evalf20.classes.andrewheiss.com/content/01-content/>)

Wie messen wir den Effekt einer Intervention?

Mit einem Experiment

Mit Beobachtungsdaten

Wie sehen diese DAGs aus?



- + **Directed:** Jede Node hat einen Pfeil der zu einer anderen Node zeigt
- + **Acyclic:** Pfeile haben nur eine Richtung, sie können nicht zu einer Node zurück

Daher können Sie DAGs folgendermaßen interpretieren:

- + Grafische Repräsentation ihres Modells
- + Jeder Pfeil zeigt eine kausale Verbindung einer Variablen zur nächsten an (Richtung der Kausalität)
- + Dort wo es keine Pfeile zwischen den Variablen gibt vermuten Sie keinen kausalen Zusammenhang (Annahmen ersichtlich)

Wie sehen diese DAGs aus?

Doch woher kommt das DAG?

Wie sehen diese DAGs aus?

Doch woher kommt das DAG?

- + Eine Sehr gute Frage!
- + Es entsteht aus ihren Erkenntnissen aus der Literatur, den eigenen Hypothesen, ökonomische Theorie, ihren eigenen Beobachtungen ...

In den folgenden Vorlesungseinheiten widmen wir uns den DAGs und wie diese den Datengenerierungsprozess veranschaulichen können.